

UNIVERSIDADE FEDERAL DE UBERLÂNDIA
FACULDADE DE COMPUTAÇÃO
PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

Disciplina: Redes Complexas

FRANCISKO ALEXANDRE DE CASTRO GÍRIO

**Detecção de Comunidades em Redes de Contato de
Proteínas**

**Validação do Pipeline com a Proteína 1A3N e Aplicação à
Proteína-Alvo 6B1T**

Professor: Prof. Dr. Gilberto Nakamura

Uberlândia
2026

Resumo

Este relatório apresenta uma versão ampliada e crítica dos resultados obtidos no projeto de Redes Complexas aplicado à análise estrutural de proteínas. O objetivo foi construir, validar e executar um pipeline computacional capaz de representar proteínas como redes de contato entre resíduos, calcular métricas topológicas, estimar centralidades, detectar comunidades e avaliar a correspondência entre os agrupamentos detectados e anotações estruturais conhecidas. A estratégia de modelagem adotou cada resíduo de aminoácido como vértice e conectou pares de resíduos quando seus átomos $C\alpha$ estavam a uma distância menor ou igual a 8 Å. O pipeline foi inicialmente validado na proteína 1A3N, com 572 resíduos e 2.828 arestas, e posteriormente aplicado à proteína-alvo 6B1T, estrutura associada ao capsídeo do adenovírus humano tipo 5, com 12.544 resíduos e 66.809 arestas na modelagem utilizada. Para ambas as redes foram calculadas distribuição de graus, métricas gerais, centralidades de grau, closeness, eigenvector, PageRank e betweenness. A detecção de comunidades foi realizada com o algoritmo Louvain. Na 6B1T, o Louvain identificou 30 comunidades com modularidade de 0,8971, indicando forte organização modular da rede. A validação biológica foi conduzida por meio de tabelas de contingência, heatmaps e métricas quantitativas comparando as comunidades com famílias estruturais anotadas no RCSB. A Purity de 0,9298 indica comunidades localmente homogêneas, enquanto os valores de ARI e NMI mostram que a correspondência global entre comunidades topológicas e famílias biológicas não é direta. Os resultados sugerem que a abordagem é adequada para revelar subestruturas espaciais coerentes, mas que a interpretação biológica deve combinar modularidade, centralidades, visualização 3D, heatmaps e anotações externas.

Palavras-chave: Redes complexas; proteínas; Louvain; centralidade; PageRank; 6B1T; comunidades.

Sumário

1	Introdução	5
2	Metodologia	5
2.1	Visão geral do pipeline	5
2.2	Estruturas analisadas	6
2.3	Construção da rede	6
2.4	Métricas topológicas e centralidades	7
2.5	Detecção de comunidades e validação	7
3	Resultados da proteína de teste 1A3N	8
3.1	Distribuição de graus	8
3.2	Centralidades	9
3.3	Comunidades	11
4	Resultados da proteína-alvo 6B1T	13
4.1	Métricas gerais da rede	14
4.2	Distribuição de graus	14
4.3	Centralidades	16
4.4	Comunidades detectadas pelo Louvain	17
4.5	Comunidade $\times$ cadeia	19
4.6	Comunidade $\times$ família estrutural	19
4.7	Validação mínima: Hexon e Penton	20
4.8	Avaliação quantitativa	21
5	Discussão	23
6	Conclusão	25
7	Declaração de colaboração e uso de Inteligência Artificial	26
A	Apêndice: tabelas complementares da proteína 1A3N	27
B	Apêndice: arquivos exportados pelo notebook	28

Lista de Figuras

1	Fluxo geral do pipeline computacional implementado no projeto.	6
2	Distribuição de graus da rede da proteína 1A3N.	9
3	Distribuição de graus da 1A3N em escala log-log.	9
4	Distribuições das centralidades calculadas para a proteína 1A3N.	10
5	Visualização tridimensional da proteína 1A3N com resíduos coloridos por comunidade Louvain.	12
6	Heatmap de correspondência entre comunidades Louvain e cadeias da proteína 1A3N.	13
7	Distribuição de graus da rede da proteína 6B1T.	15
8	Distribuição de graus da 6B1T em escala log-log.	15
9	Distribuições das centralidades calculadas para a proteína 6B1T.	16
10	Visualização tridimensional da proteína 6B1T com resíduos coloridos por comunidade Louvain.	18
11	Heatmap de correspondência entre comunidades Louvain e cadeias da proteína 6B1T.	19
12	Heatmap de correspondência entre comunidades Louvain e famílias estruturais da 6B1T.	21
13	Heatmap de correspondência entre comunidades Louvain e grupos estruturais mínimos: Hexon, Penton e outras proteínas.	22
14	Resumo gráfico das métricas quantitativas de validação biológica da 6B1T.	22

Lista de Tabelas

1	Proteínas utilizadas no projeto.	6
2	Parâmetros principais da modelagem.	7
3	Métricas da rede construída para a proteína 1A3N.	8
4	Top 10 resíduos da 1A3N por grau.	10
5	Top 10 resíduos da 1A3N por PageRank.	11
6	Resumo da detecção de comunidades para a 1A3N.	11
7	Tamanho das comunidades detectadas na 1A3N.	12
8	Métricas da rede construída para a proteína 6B1T.	14
9	Tempo aproximado de cálculo das centralidades da 6B1T.	17
10	Quinze maiores comunidades detectadas na 6B1T.	17
11	Famílias estruturais identificadas na proteína 6B1T.	20
12	Métricas quantitativas de validação da 6B1T.	21
13	Síntese interpretativa dos principais resultados da 6B1T.	23
14	Top 10 resíduos da 1A3N por betweenness.	27
15	Top 10 resíduos da 1A3N por eigenvector centrality.	27

1 Introdução

Proteínas são estruturas tridimensionais formadas por cadeias de aminoácidos cujo arranjo espacial determina propriedades estruturais e funcionais. Em vez de analisar apenas a sequência linear de resíduos, uma alternativa consiste em representar a proteína como uma rede de contatos. Nessa representação, cada resíduo é tratado como um vértice, e as relações de proximidade espacial entre resíduos são tratadas como arestas. Essa modelagem permite aplicar ferramentas de Redes Complexas para investigar conectividade, modularidade, centralidade e organização estrutural.

O projeto da disciplina propõe consolidar conceitos de modelagem de redes, medidas de centralidade e detecção de comunidades por meio da análise estrutural de proteínas. O alvo preferencial indicado foi a estrutura 6B1T, associada ao adenovírus humano tipo 5. Por se tratar de uma estrutura grande, o enunciado recomenda validar o pipeline em uma proteína menor antes da execução no alvo principal. Por esse motivo, a proteína 1A3N foi utilizada como estrutura de teste.

A questão central investigada neste trabalho é se comunidades detectadas em uma rede de contatos entre resíduos podem revelar agrupamentos estruturalmente coerentes e, no caso da 6B1T, apresentar relação com famílias estruturais anotadas no RCSB. Essa relação não é necessariamente perfeita, pois uma comunidade topológica é definida pela conectividade da rede, enquanto uma família estrutural é definida por uma anotação biológica externa. Ainda assim, a comparação entre essas duas perspectivas permite avaliar em que medida a organização espacial da proteína é capturada pela rede.

Este relatório foi elaborado a partir dos resultados efetivamente gerados pelo notebook do projeto. A organização segue o fluxo computacional executado: obtenção e leitura dos arquivos PDB, extração dos resíduos, construção da rede, cálculo de métricas, análise de centralidades, aplicação do Louvain, geração de heatmaps e validação biológica. A proteína 1A3N é tratada como validação inicial do pipeline, enquanto a proteína 6B1T concentra a análise principal.

2 Metodologia

2.1 Visão geral do pipeline

A Figura 1 apresenta o fluxo geral implementado no notebook. O processo parte do arquivo PDB, realiza o parsing das coordenadas, extrai os resíduos representados pelo átomo $C\alpha$, constrói a rede por proximidade espacial, calcula centralidades, aplica o Louvain e compara as comunidades detectadas com anotações estruturais.

A opção por organizar o código em funções reutilizáveis permitiu aplicar o mesmo




Figura 1: Fluxo geral do pipeline computacional implementado no projeto.

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

conjunto de procedimentos à proteína de teste e à proteína-alvo. Essa padronização reduz a possibilidade de diferenças artificiais entre as execuções e torna a comparação entre resultados mais consistente.

2.2 Estruturas analisadas

Foram analisadas duas estruturas proteicas. A proteína 1A3N foi utilizada como caso de teste, enquanto a 6B1T foi utilizada como alvo principal. A Tabela 1 resume o papel de cada estrutura.

Tabela 1: Proteínas utilizadas no projeto.

PDB	Finalidade no projeto	Uso no relatório
1A3N	Proteína de teste utilizada para verificar leitura, parsing, construção da rede, cálculo de centralidades, Louvain e exportação dos resultados.	Validação inicial
6B1T	Proteína-alvo indicada no projeto, associada ao capsídeo do adenovírus humano tipo 5.	Análise principal

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

2.3 Construção da rede

Cada proteína foi modelada como um grafo não direcionado. Cada nó corresponde a um resíduo de aminoácido, identificado por cadeia, nome do resíduo e número do resíduo. A posição espacial de cada nó foi definida pelas coordenadas do átomo C α . Dois resíduos foram conectados por uma aresta quando a distância euclidiana entre os respectivos átomos C α foi menor ou igual a 8 Å.

A escolha por uma rede no nível de resíduos reduz a complexidade em relação a uma rede atômica e mantém a interpretação em uma escala compatível com a análise estrutural. A busca de vizinhos foi realizada com KDTTree, evitando o cálculo exaustivo de todas as distâncias par a par. A Tabela 2 apresenta os principais parâmetros da modelagem.

Tabela 2: Parâmetros principais da modelagem.

Item	Escolha adotada
Tipo de nó	Resíduo de aminoácido representado pelo átomo C α
Tipo de aresta	Contato espacial entre resíduos
Critério de conexão	Distância C α –C α menor ou igual a 8 Å
Tipo de grafo	Não direcionado
Peso das arestas	Peso unitário na detecção de comunidades
Bibliotecas principais	Biopython, NetworkX, SciPy, Python-Louvain, Pandas, Matplotlib e Plotly
Algoritmo de comunidades	Louvain

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

2.4 Métricas topológicas e centralidades

Para cada rede foram calculados número de nós, número de arestas, densidade, grau médio, grau máximo, coeficiente médio de agrupamento, número de componentes conectados e tamanho do maior componente. Essas métricas caracterizam a escala da rede e sua conectividade global.

Também foram calculadas cinco centralidades: grau, closeness, eigenvector, PageRank e betweenness. A centralidade de grau destaca resíduos com mais contatos locais. A closeness identifica resíduos próximos, em média, dos demais vértices da rede. A eigenvector centrality atribui maior importância a resíduos conectados a outros resíduos relevantes. O PageRank estima relevância pela propagação de importância na rede. A betweenness identifica resíduos que participam de caminhos entre regiões distintas, podendo indicar interfaces estruturais.

Na 6B1T, a betweenness foi calculada de forma aproximada, com amostragem de 300 fontes, devido ao custo computacional da medida exata em uma rede com mais de 12 mil nós. O próprio notebook registrou tempo total de aproximadamente 196,4 segundos para o cálculo das centralidades da 6B1T, sendo a closeness a etapa mais demorada.

2.5 Detecção de comunidades e validação

A detecção de comunidades foi realizada pelo algoritmo Louvain, com resolução igual a 1,0. O algoritmo atribui a cada resíduo um identificador de comunidade e otimiza a modularidade da rede. Após a detecção, foram geradas tabelas de contingência cruzando comunidades com cadeias e, no caso da 6B1T, com famílias estruturais derivadas das anotações do RCSB.

A avaliação quantitativa da 6B1T utilizou modularidade, Purity, Adjusted Rand Index (ARI), Normalized Mutual Information (NMI), homogeneidade e completude. Es-

As métricas devem ser interpretadas em conjunto. A modularidade avalia a qualidade topológica da partição. A Purity indica predominância local de uma classe em cada comunidade. ARI e NMI avaliam correspondência global entre duas partições, penalizando situações em que uma mesma família biológica aparece fragmentada em várias comunidades.

3 Resultados da proteína de teste 1A3N

A proteína 1A3N foi utilizada para validar o pipeline antes da aplicação à proteína-alvo. A execução carregou 572 resíduos distribuídos em quatro cadeias. A rede construída possui 2.828 arestas e forma um único componente conectado. A Tabela 3 apresenta as principais métricas da rede.

Tabela 3: Métricas da rede construída para a proteína 1A3N.

Métrica	Valor
Nós	572
Arestas	2.828
Densidade	0,0173
Grau médio	9,8881
Grau máximo	17
Coefficiente de agrupamento médio	0,5449
Componentes conectados	1
Maior componente	572

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

A densidade da rede da 1A3N é baixa, mas o grafo é conectado. Esse resultado é coerente com uma rede geométrica: cada resíduo se conecta apenas aos resíduos próximos no espaço tridimensional, e não a todos os demais resíduos da proteína.

3.1 Distribuição de graus

A Figura 2 apresenta a distribuição de graus da 1A3N. Os resíduos concentram-se principalmente em graus intermediários, entre 8 e 12, com poucos vértices atingindo os maiores valores de conectividade. O grau máximo observado foi 17.

A Figura 3 mostra a distribuição em escala log-log. Para uma rede desse tamanho, a escala log-log é útil como inspeção exploratória, mas não permite concluir a existência de uma lei de potência. O comportamento observado é mais compatível com uma rede espacial de grau limitado.




Figura 2: Distribuição de graus da rede da proteína 1A3N.

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.




Figura 3: Distribuição de graus da 1A3N em escala log-log.

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

3.2 Centralidades

A Figura 4 apresenta os histogramas das centralidades calculadas para a 1A3N. A maior parte dos resíduos apresenta valores baixos ou intermediários, enquanto poucos resíduos se destacam em cada métrica. Esse padrão é esperado em uma estrutura física, na qual a conectividade local é limitada pela geometria da proteína.

A Tabela 4 mostra os dez maiores valores de grau na 1A3N. Esses resíduos representam regiões localmente mais conectadas da estrutura.




Figura 4: Distribuições das centralidades calculadas para a proteína 1A3N.

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

Tabela 4: Top 10 resíduos da 1A3N por grau.

Nó	Cadeia	Resíduo	Número	Grau
344	C	GLY	59	17
200	B	LYS	61	17
163	B	GLY	24	16
87	A	ALA	88	16
373	C	ALA	88	16
310	C	GLY	25	16
489	D	GLY	64	16
486	D	LYS	61	16
203	B	GLY	64	16
58	A	GLY	59	16

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

A Tabela 5 apresenta os maiores valores de PageRank. Embora PageRank seja frequentemente associado a redes direcionadas, sua aplicação em grafos não direcionados permite identificar resíduos que recebem importância topológica a partir de seus vizinhos.

Tabela 5: Top 10 resíduos da 1A3N por PageRank.

Nó	Cadeia	Resíduo	Número	PageRank
373	C	ALA	88	0,0027
87	A	ALA	88	0,0027
200	B	LYS	61	0,0026
344	C	GLY	59	0,0026
518	D	CYS	93	0,0026
232	B	CYS	93	0,0026
486	D	LYS	61	0,0025
58	A	GLY	59	0,0025
566	D	LEU	141	0,0025
489	D	GLY	64	0,0025

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

3.3 Comunidades

A aplicação do Louvain à rede da 1A3N resultou em 14 comunidades, com modularidade de 0,7714. Esse valor indica que o grafo apresenta estrutura modular clara. A Tabela 6 apresenta as métricas de comparação entre comunidades e cadeias.

Tabela 6: Resumo da detecção de comunidades para a 1A3N.

Métrica	Valor
Modularidade	0,7714
ARI comunidade $\times$ cadeia	0,2877
NMI comunidade $\times$ cadeia	0,5487

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

A Tabela 7 mostra o tamanho das comunidades detectadas. A distribuição dos tamanhos revela que o Louvain fragmentou a estrutura em sub-regiões, e não em quatro grupos equivalentes às cadeias.

A Figura 5 apresenta a visualização tridimensional da 1A3N com os resíduos coloridos conforme a comunidade detectada pelo Louvain. A figura complementa a análise quantitativa ao mostrar que a partição obtida não é apenas uma divisão numérica do grafo: as comunidades ocupam regiões reconhecíveis da estrutura, ainda que existam contatos e interfaces entre grupos diferentes.

Tabela 7: Tamanho das comunidades detectadas na 1A3N.

Comunidade	Quantidade de resíduos
4	59
7	56
11	54
8	51
6	47
13	44
5	40
10	39
12	38
0	38
3	33
2	31
1	24
9	18

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

Visualização 3D da proteína 1A3N com comunidades Louvain




Figura 5: Visualização tridimensional da proteína 1A3N com resíduos coloridos por comunidade Louvain.

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

A Figura 6 apresenta o heatmap comunidade $\times$ cadeia. O resultado mostra que a correspondência entre comunidade e cadeia não é direta. Isso não representa falha do

pipeline; indica que, mesmo em uma proteína menor, o Louvain identifica agrupamentos topológicos internos que podem dividir cadeias ou capturar contatos entre elas.




Figura 6: Heatmap de correspondência entre comunidades Louvain e cadeias da proteína 1A3N.

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

A etapa com a 1A3N cumpriu sua função metodológica: validar o carregamento do PDB, a extração dos resíduos $C\alpha$, a construção da rede, a geração de figuras, o cálculo de centralidades, a detecção de comunidades e a exportação dos resultados.

4 Resultados da proteína-alvo 6B1T

A 6B1T foi a proteína-alvo principal do projeto. A estrutura foi carregada a partir dos dois arquivos do bundle PDB. A execução extraiu 12.544 resíduos distribuídos em 25 cadeias. A rede construída possui 66.809 arestas e forma um único componente conectado, o que indica que todos os resíduos carregados participam da mesma estrutura de contatos.

4.1 Métricas gerais da rede

A Tabela 8 apresenta as principais métricas da rede da 6B1T. O contraste com a 1A3N é evidente: a rede da 6B1T é muito maior, mas continua esparsa, como esperado para uma rede baseada em contatos espaciais.

Tabela 8: Métricas da rede construída para a proteína 6B1T.

Métrica	Valor
Nós	12.544
Arestas	66.809
Densidade	0,0008
Grau médio	10,6519
Grau máximo	20
Coefficiente de agrupamento médio	0,4975
Componentes conectados	1
Maior componente	12.544

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

A densidade de 0,000849 indica que apenas uma fração muito pequena dos pares possíveis de resíduos está conectada. Isso é coerente com a modelagem: a aresta representa proximidade física em até 8 Å. O grau médio de 10,65 mostra que cada resíduo se conecta, em média, a cerca de onze resíduos vizinhos. O grau máximo de 20 reforça a interpretação de uma rede geométrica de grau limitado, sem hubs extremos.

4.2 Distribuição de graus

A Figura 7 apresenta a distribuição de graus da 6B1T. A maior parte dos resíduos concentra-se em uma faixa intermediária de conectividade, com pico próximo ao grau médio.

Esse resultado confirma que a rede não possui comportamento dominado por poucos nós altamente conectados. Diferentemente de redes sociais ou tecnológicas, a rede de contato proteica é limitada pela geometria tridimensional da molécula. O número de contatos de um resíduo depende do empacotamento local e do limiar espacial adotado.

A Figura 8 apresenta a distribuição em escala log-log. O gráfico evidencia a cauda da distribuição, mas não sugere uma rede livre de escala. O comportamento é mais compatível com uma rede espacial, em que a conectividade é controlada por restrições físicas.




Figura 7: Distribuição de graus da rede da proteína 6B1T.

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.




Figura 8: Distribuição de graus da 6B1T em escala log-log.

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

4.3 Centralidades

A Figura 9 apresenta os histogramas das centralidades calculadas para a 6B1T. O cálculo incluiu centralidade de grau, closeness, eigenvector, PageRank e betweenness. A betweenness foi estimada por amostragem devido ao tamanho da rede.




Figura 9: Distribuições das centralidades calculadas para a proteína 6B1T.

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

As distribuições de grau e PageRank apresentam concentração em torno de valores intermediários, acompanhando a conectividade local da rede. A eigenvector centrality aparece fortemente concentrada em valores baixos, indicando que poucos resíduos ocupam posições associadas a regiões de maior influência topológica. A betweenness também apresenta distribuição bastante assimétrica, com muitos resíduos próximos de zero e poucos atuando como potenciais pontos de passagem entre regiões da estrutura.

O notebook registrou o progresso da execução das centralidades da 6B1T. A closeness foi a etapa mais custosa, exigindo aproximadamente 148,5 segundos, seguida da eigenvector centrality com 25,7 segundos e da betweenness aproximada com 21,8 segundos. A Tabela 9 resume esse comportamento.

Tabela 9: Tempo aproximado de cálculo das centralidades da 6B1T.

Etapa	Tempo aproximado
Degree	0,0 s
Closeness	148,5 s
Eigenvector	25,7 s
PageRank	0,1 s
Betweenness aproximada (k=300)	21,8 s
Tempo total	196,4 s

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

Essa diferença de custo computacional é relevante para a interpretação do projeto, pois mostra que a escolha de aproximação para betweenness foi necessária para viabilizar a análise em uma estrutura com 12.544 resíduos. A presença de arquivos exportados com os Top-20 de cada centralidade no diretório de resultados também permite inspeção posterior dos resíduos mais relevantes.

4.4 Comunidades detectadas pelo Louvain

A aplicação do Louvain à rede da 6B1T resultou em 30 comunidades e modularidade igual a 0,8971. Esse valor é elevado e indica forte organização modular. A Tabela 10 apresenta as maiores comunidades detectadas.

Tabela 10: Quinze maiores comunidades detectadas na 6B1T.

Comunidade	Quantidade de resíduos
16	701
21	623
10	600
1	598
28	573
2	557
11	555
27	540
12	526
26	516
18	515
5	515
6	495
4	492
20	480

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

As comunidades apresentam tamanhos heterogêneos, variando de grupos pequenos, com menos de 50 resíduos, até comunidades com mais de 700 resíduos. Essa heterogeneidade reflete a própria organização do capsídeo, no qual grandes unidades estruturais coexistem com proteínas menores e regiões de interface.

A Figura 10 apresenta a visualização tridimensional da 6B1T com os resíduos coloridos por comunidade Louvain. Essa figura é central para a validação qualitativa, pois permite observar se os agrupamentos estão espacialmente organizados.

Visualização 3D da proteína 6B1T com comunidades Louvain




Figura 10: Visualização tridimensional da proteína 6B1T com resíduos coloridos por comunidade Louvain.

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

A visualização indica que as comunidades ocupam regiões espacialmente coerentes, embora existam interfaces entre agrupamentos. Esse comportamento é esperado em uma proteína grande: diferentes unidades estruturais mantêm contatos físicos, e o Louvain tende a separar regiões densamente conectadas, preservando algumas interfaces. A figura também reforça a relação direta entre a modelagem por distância e a detecção de comunidades, pois as cores revelam agrupamentos organizados no espaço tridimensional.

4.5 Comunidade $\times$ cadeia

A Figura 11 apresenta o heatmap comunidade $\times$ cadeia. Cada célula representa o número de resíduos de uma cadeia pertencentes a uma comunidade. Células mais claras indicam maior concentração de resíduos.




Figura 11: Heatmap de correspondência entre comunidades Louvain e cadeias da proteína 6B1T.

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

O heatmap mostra que algumas comunidades concentram resíduos de cadeias específicas, enquanto outras distribuem resíduos entre cadeias diferentes. Isso é coerente com a finalidade do algoritmo: o Louvain não busca reproduzir cadeias, mas detectar regiões de maior conectividade interna. Portanto, uma comunidade pode atravessar limites de cadeia quando há contato espacial entre elas.

4.6 Comunidade $\times$ família estrutural

Para aproximar a análise da validação biológica proposta no projeto, as cadeias da 6B1T foram mapeadas para famílias estruturais. A Tabela 11 apresenta a contagem de resíduos por família.

Tabela 11: Famílias estruturais identificadas na proteína 6B1T.

Família estrutural	Quantidade de resíduos
Hexon protein	10.925
Penton protein	455
Hexon-interlacing protein	386
Pre-hexon-linking protein VIII	360
Pre-hexon-linking protein IIIa	288
Pre-protein VI	119
Pre-histone-like nucleoprotein	11

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

A família Hexon protein domina a estrutura, com 10.925 resíduos, representando a maior parte da 6B1T. Essa dominância influencia diretamente as métricas de validação: uma única família biológica aparece distribuída em muitas comunidades topológicas, reduzindo métricas globais como ARI e NMI, mesmo quando as comunidades são localmente coerentes.

A Figura 12 apresenta o heatmap comunidade $\times$ família estrutural. Essa figura é uma das mais relevantes do relatório, pois relaciona diretamente as comunidades obtidas pelo Louvain com anotações estruturais conhecidas.

O heatmap mostra que a família Hexon aparece em várias comunidades, o que confirma sua predominância estrutural. Também é possível identificar comunidades associadas a Penton protein, Hexon-interlacing protein e proteínas de ligação pré-hexon. A interpretação mais adequada é que o Louvain identifica subestruturas topológicas dentro de famílias maiores, em vez de reproduzir diretamente as classes biológicas completas.

4.7 Validação mínima: Hexon e Penton

O enunciado do projeto define como detecção mínima esperada a separação entre as principais unidades estruturais: penton, associado à base, e hexon, associado ao capsídeo. Para avaliar essa condição, o notebook agrupou as famílias em três categorias: Hexon/capsídeo, Penton/base e outras proteínas. A Figura 13 apresenta o heatmap resultante.

A figura mostra que a maior parte dos resíduos pertence ao grupo Hexon/capsídeo, enquanto o grupo Penton/base aparece fortemente concentrado em comunidade específica. Essa concentração sugere que a detecção mínima foi parcialmente capturada. Entretanto, a separação não deve ser interpretada como classificação perfeita, pois algumas comunidades contêm contribuições de diferentes grupos estruturais.




Figura 12: Heatmap de correspondência entre comunidades Louvain e famílias estruturais da 6B1T.

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

4.8 Avaliação quantitativa

A Tabela 12 apresenta as métricas quantitativas calculadas para a validação biológica da 6B1T.

Tabela 12: Métricas quantitativas de validação da 6B1T.

Métrica	Valor
Modularidade	0,8971
Purity	0,9298
Adjusted Rand Index (ARI)	0,0116
Normalized Mutual Information (NMI)	0,1928
Homogeneity	0,6414
Completeness	0,1134

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

A Figura 14 apresenta essas métricas em forma gráfica. A visualização evidencia o contraste entre modularidade e Purity elevadas, de um lado, e ARI e NMI baixos, de




Figura 13: Heatmap de correspondência entre comunidades Louvain e grupos estruturais mínimos: Hexon, Penton e outras proteínas.

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

outro.




Figura 14: Resumo gráfico das métricas quantitativas de validação biológica da 6B1T.

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

A modularidade elevada indica que o Louvain encontrou uma partição topologica-

mente forte. A Purity de 0,9298 sugere que muitas comunidades possuem predominância de uma mesma família estrutural. Contudo, o ARI de 0,0116 e o NMI de 0,1928 mostram que a correspondência global entre comunidades e famílias estruturais é baixa. Essa diferença não invalida o resultado; ela indica que a partição topológica fragmenta famílias grandes, especialmente Hexon, em várias comunidades espacialmente coerentes.

Tabela 13: Síntese interpretativa dos principais resultados da 6B1T.

Resultado	Valor	Interpretação
Nós	12.544	Estrutura de grande porte, com resíduos suficientes para análise modular.
Arestas	66.809	Rede conectada por proximidade espacial $C\alpha$ – $C\alpha$.
Grau médio	10,65	Conectividade local limitada por restrições físicas.
Comunidades	30	Louvain fragmenta a estrutura em regiões topológicas.
Modularidade	0,8971	Forte separação modular da rede.
Purity	0,9298	Muitas comunidades são dominadas por uma família estrutural.
ARI	0,0116	Baixa equivalência global entre comunidades e famílias.
NMI	0,1928	Correspondência parcial entre partição topológica e anotação biológica.

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

A análise conjunta mostra que o resultado não deve ser reduzido a uma única métrica. Modularidade, visualização 3D, heatmaps e Purity apontam para agrupamentos coerentes; ARI e NMI indicam que esses agrupamentos não são equivalentes diretos às famílias estruturais completas. Essa interpretação é compatível com a natureza do Louvain e com a composição da 6B1T.

5 Discussão

Os resultados obtidos confirmam que a modelagem de proteínas como redes de contato entre resíduos é adequada para investigar organização estrutural por meio de métricas de Redes Complexas. A estratégia baseada no átomo $C\alpha$ e no limiar de 8 Å produziu grafos conectados tanto para a 1A3N quanto para a 6B1T. Essa conectividade é importante porque permite calcular medidas globais e aplicar algoritmos de comunidades sem necessidade de tratar componentes desconectados.

A proteína 1A3N cumpriu o papel de validação inicial. A rede apresentou 572 nós, 2.828 arestas e modularidade de 0,7714. O Louvain encontrou 14 comunidades, mostrando que mesmo uma proteína de teste pode apresentar subdivisões topológicas internas. A baixa correspondência direta entre comunidades e cadeias indica que a unidade detectada

pelo algoritmo não é necessariamente a cadeia, mas sim uma região de contatos mais densos.

Na 6B1T, a rede obtida foi significativamente maior, com 12.544 nós e 66.809 arestas. A densidade baixa e o grau médio de aproximadamente 10,65 são coerentes com a natureza geométrica da rede. Em estruturas físicas, um resíduo não pode se conectar a um número arbitrariamente grande de outros resíduos, pois sua vizinhança é limitada pelo espaço tridimensional. Por isso, a distribuição de graus da 6B1T não apresenta hubs extremos.

A modularidade de 0,8971 é um dos resultados mais relevantes do trabalho. Esse valor indica que a rede apresenta organização modular forte. Em termos estruturais, isso sugere que os resíduos formam agrupamentos com alta conectividade interna e menor conectividade externa. Essa propriedade é compatível com a hipótese central do projeto: regiões estruturalmente organizadas podem emergir como comunidades em redes de contato.

As centralidades complementam essa interpretação. O grau destaca regiões localmente empacotadas. O PageRank valoriza resíduos conectados a regiões também relevantes. A eigenvector centrality enfatiza influência topológica dentro de regiões densas. A betweenness, mesmo calculada de forma aproximada, é especialmente importante para identificar potenciais interfaces entre módulos. Esses resultados não substituem uma análise bioquímica específica, mas fornecem uma caracterização topológica útil da estrutura.

A validação biológica da 6B1T exige cuidado. A Purity elevada indica que muitas comunidades são internamente homogêneas em relação às famílias estruturais. Entretanto, ARI e NMI baixos mostram que a partição como um todo não reproduz diretamente os rótulos de família. Essa aparente contradição é explicável pela composição da proteína: a família Hexon representa a maior parte dos resíduos e aparece distribuída em várias comunidades. Assim, o Louvain não recupera a família Hexon como um único bloco, mas a divide em subestruturas topológicas.

Essa fragmentação não deve ser interpretada necessariamente como falha. O objetivo do Louvain é maximizar modularidade, não reproduzir anotações biológicas. Quando uma família estrutural é muito grande, é natural que ela contenha subcomunidades internas. Nesse sentido, os heatmaps e a visualização tridimensional são essenciais: eles mostram que a partição possui coerência espacial, ainda que não coincida exatamente com as famílias anotadas.

A análise mínima Hexon/Penton também oferece uma leitura importante. O Penton aparece mais concentrado do que a família Hexon, enquanto Hexon domina diversas comunidades. Esse resultado sugere que a separação das principais unidades estruturais foi parcialmente capturada. O método identifica padrões de proximidade estrutural, mas

não deve ser tratado como classificador supervisionado de famílias.

Do ponto de vista computacional, o uso de KDTree foi fundamental para tornar viável a construção da rede. Sem essa estrutura, seria necessário calcular todas as distâncias entre pares de resíduos, o que aumentaria muito o custo para a 6B1T. O tempo registrado para as centralidades também mostra que redes proteicas grandes exigem escolhas pragmáticas, como o uso de betweenness aproximada.

Uma limitação importante do trabalho é a escolha fixa do limiar de 8 Å. Esse valor é comum em análises baseadas em $C\alpha$, mas diferentes limiares poderiam alterar a densidade da rede e, consequentemente, as comunidades detectadas. Outra limitação é o uso de peso unitário na detecção de comunidades. Pesos baseados em distância, número de contatos atômicos ou propriedades físico-químicas poderiam produzir partições diferentes.

Como extensões futuras, seria possível comparar Louvain com Leiden, Infomap ou bipartição espectral; avaliar diferentes limiares de distância; usar pesos inversamente proporcionais à distância; comparar comunidades em diferentes resoluções; e investigar se resíduos com alta betweenness correspondem a interfaces relevantes em visualizadores estruturais. Também seria possível usar as tabelas exportadas pelo notebook para selecionar resíduos de alto PageRank ou alta betweenness e analisá-los diretamente na estrutura 3D.

Em síntese, o trabalho mostra que a modelagem por redes complexas não substitui a anotação biológica, mas oferece uma perspectiva complementar. A rede revela a organização espacial e modular da estrutura. As anotações do RCSB fornecem referência funcional e estrutural. A combinação das duas permite interpretar de forma mais rica a proteína 6B1T.

6 Conclusão

Este trabalho desenvolveu e executou um pipeline para análise de proteínas como redes complexas, utilizando resíduos de aminoácidos como nós e contatos espaciais $C\alpha$ - $C\alpha$ como arestas. A estratégia foi validada inicialmente na proteína 1A3N e, em seguida, aplicada à proteína-alvo 6B1T.

A execução na 1A3N confirmou o funcionamento do pipeline em uma estrutura menor. Foram realizadas leitura do PDB, extração dos resíduos, construção da rede, cálculo de métricas, análise de centralidades, detecção de comunidades, geração de heatmaps e exportação dos resultados.

Na 6B1T, a rede construída apresentou 12.544 nós, 66.809 arestas e um único componente conectado. O algoritmo Louvain identificou 30 comunidades com modularidade de 0,8971, indicando forte estrutura modular. A distribuição de graus e os histogramas

de centralidades mostraram comportamento compatível com uma rede geométrica de contatos espaciais, sem hubs extremos e com conectividade limitada pela estrutura física da proteína.

A validação biológica mostrou resultados complementares. A Purity elevada indica que muitas comunidades são dominadas por uma família estrutural. Entretanto, ARI e NMI baixos indicam que as comunidades não reproduzem globalmente as famílias anotadas. Essa diferença é explicada principalmente pela predominância da família Hexon, que aparece distribuída em várias comunidades topológicas.

Conclui-se que o Louvain identificou agrupamentos estruturalmente coerentes na rede de contato da 6BIT, mas esses agrupamentos devem ser interpretados como subestruturas topológicas, e não como equivalentes diretos das famílias biológicas completas. A análise mais adequada combina modularidade, distribuição de graus, centralidades, visualização 3D, heatmaps e métricas de validação.

O projeto atende ao objetivo proposto ao consolidar modelagem de redes, centralidades e detecção de comunidades em uma aplicação estrutural de proteínas. Além disso, o notebook gerado fornece uma base reprodutível para futuras análises com outras proteínas, outros limiares de distância ou algoritmos alternativos de detecção de comunidades.

7 Declaração de colaboração e uso de Inteligência Artificial

O desenvolvimento deste projeto foi realizado pelo autor, desde a implementação do código até a análise dos resultados e a elaboração deste relatório.

Ao longo do trabalho, foram realizadas conversas com o colega Pedro Henrique Bernardes Caetano Milken para esclarecimento de dúvidas relacionadas às orientações da disciplina, discussão de aspectos gerais da metodologia empregada e interpretação de alguns resultados obtidos durante a execução do projeto. Essas conversas tiveram caráter exclusivamente acadêmico e não envolveram compartilhamento de código, desenvolvimento conjunto da solução ou redação deste relatório.

Também foi utilizada a ferramenta de Inteligência Artificial ChatGPT, da OpenAI, como recurso de apoio ao desenvolvimento do projeto. Sua utilização restringiu-se ao auxílio na validação do código implementado, identificação de possíveis inconsistências, esclarecimento de dúvidas técnicas sobre algoritmos e bibliotecas empregadas, além de sugestões para organização do notebook e aprimoramento da redação do relatório.

Todas as implementações, adaptações, testes e decisões metodológicas foram realizadas e verificadas pelo autor, que assume integral responsabilidade pelos resultados

apresentados e pelas conclusões deste trabalho.

A Apêndice: tabelas complementares da proteína 1A3N

Este apêndice reúne tabelas complementares extraídas da execução do notebook. Elas não são essenciais para a leitura principal do relatório, mas demonstram que o pipeline exportou resultados detalhados de centralidade.

Tabela 14: Top 10 resíduos da 1A3N por betweenness.

Nó	Cadeia	Resíduo	Número	Betweenness
34	A	SER	35	0,0532
247	B	ASN	108	0,0523
320	C	SER	35	0,0521
379	C	ASP	94	0,0512
322	C	PRO	37	0,0471
36	A	PRO	37	0,0468
102	A	HIS	103	0,0464
388	C	HIS	103	0,0459
533	D	ASN	108	0,0448
93	A	ASP	94	0,0435

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

Tabela 15: Top 10 resíduos da 1A3N por eigenvector centrality.

Nó	Cadeia	Resíduo	Número	Eigenvector
203	B	GLY	64	0,2700
163	B	GLY	24	0,2610
164	B	GLY	25	0,2582
200	B	LYS	61	0,2550
204	B	LYS	65	0,2259
167	B	LEU	28	0,2045
165	B	GLU	26	0,2003
162	B	VAL	23	0,1981
160	B	ASP	21	0,1941
168	B	GLY	29	0,1885

Fonte: Elaboração do autor, a partir da execução do notebook do projeto.

B Apêndice: arquivos exportados pelo notebook

A execução do notebook exportou arquivos CSV, PNG e HTML para as proteínas 1A3N e 6B1T. Entre os artefatos gerados estão: arquivos de resíduos $C\alpha$, arestas da rede, métricas gerais, distribuição de graus, centralidades completas, Top-20 por centralidade, comunidades Louvain, tabelas de contingência, heatmaps, métricas de validação biológica e visualizações 3D interativas. Esses arquivos devem acompanhar o repositório GitHub do projeto para permitir reprodutibilidade.

Referências

- [1] BARABÁSI, A.-L.; OLTVAI, Z. N. Network biology: understanding the cell's functional organization. *Nature Reviews Genetics*, v. 5, p. 101–113, 2004.
- [2] BERMAN, H. M. et al. The Protein Data Bank. *Nucleic Acids Research*, v. 28, n. 1, p. 235–242, 2000.
- [3] BLONDEL, V. D.; GUILLAUME, J.-L.; LAMBIOTTE, R.; LEFEBVRE, E. Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment*, 2008.
- [4] COCK, P. J. A. et al. Biopython: freely available Python tools for computational molecular biology and bioinformatics. *Bioinformatics*, v. 25, n. 11, p. 1422–1423, 2009.
- [5] HAGBERG, A. A.; SCHULT, D. A.; SWART, P. J. Exploring network structure, dynamics, and function using NetworkX. In: *Proceedings of the 7th Python in Science Conference*, 2008.
- [6] NEWMAN, M. E. J. Modularity and community structure in networks. *Proceedings of the National Academy of Sciences*, v. 103, n. 23, p. 8577–8582, 2006.
- [7] NEWMAN, M. E. J. *Networks: An Introduction*. Oxford: Oxford University Press, 2010.
- [8] RCSB Protein Data Bank. *Structure 1A3N*. Disponível em: <https://www.rcsb.org/structure/1A3N>. Acesso em: 2026.
- [9] RCSB Protein Data Bank. *Structure 6B1T*. Disponível em: <https://www.rcsb.org/structure/6B1T>. Acesso em: 2026.
- [10] RCSB Protein Data Bank. *Annotations for 6B1T*. Disponível em: <https://www.rcsb.org/annotations/6B1T>. Acesso em: 2026.
- [11] RCSB Protein Data Bank. *3D View - 6B1T*. Disponível em: <https://www.rcsb.org/3d-view/6B1T>. Acesso em: 2026.
- [12] VIRTANEN, P. et al. SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nature Methods*, v. 17, p. 261–272, 2020.