

Detecção de Domínios Funcionais

Modelagem de Redes Complexas em Proteínas

Proteína de Teste

1A3N

Hemoglobina humana

4 cadeias (A, B, C, D)

574 resíduos

Proteína-Alvo

6B1T

Adenovírus Humano 5

25 cadeias (A–Y)

~38 000 resíduos

Pipeline de Execução

Fluxo completo — do arquivo PDB até a validação biológica

1

Dados PDB

Download 1A3N
automático
Upload manual 6B1T
(2 bundles PDB)

2

Construção da Rede

Grafo não-dirigido
Arestas: $C\alpha-C\alpha \leq 8 \text{ \AA}$
KDTTree (scipy)

3

Análise Topológica

Distribuição de graus
Degree, Closeness,
Eigenvector,
PageRank,
Betweenness

4

Louvain

Detecção de
comunidades
Resolução: 1.0
Betweenness aprox.
($k=300$) na 6B1T

5

Validação

Comunidade × Cadeia
Comunidade × Família
RCSB
ARI, NMI, Purity,
Homogeneity,
Completeness

Instalação e Pré-requisitos

Ambiente: Google Colab (recomendado) · Python ≥ 3.9

Bibliotecas Python

biopython — Parse de arquivos PDB

networkx — Construção e análise da rede

python-louvain — Detecção de comunidades

plotly — Visualização 3D interativa

pandas / numpy — Manipulação de dados

scipy — KDTree — busca por distância

scikit-learn — Métricas de validação (ARI, NMI...)

matplotlib — Histogramas e heatmaps

kaleido — Exportação de figuras PNG

```
# Célula 1 — instalação
import sys, subprocess
subprocess.check_call([
    sys.executable, "-m",
    "pip", "install", "-q",
    "biopython", "networkx",
    "python-louvain",
    "plotly", "pandas",
    "scipy", "scikit-learn",
    "matplotlib", "kaleido"])
```

Arquivos PDB necessários:

1A3N → download automático:
(função: `baixar_pdb()`)

6B1T → upload manual:

`6b1t-pdb-bundle1.pdb`

`6b1t-pdb-bundle2.pdb`

(extraídos do tar.gz do RCSB)

Proteína de Teste — 1A3N

Hemoglobina humana · Validação do pipeline antes da execução no alvo

5-6

Obter & Parsear

`baixar_pdb()` → `carregar_residuos_ca()`

Download automático · extrai Cα de 4 cadeias (A–D)

7

Construir rede

`construir_rede_por_distancia(df, 8.0)`

574 nós · ~3 490 arestas · exporta CSV

8

Distribuição de graus

`plot_distribuicao_graus(G_1a3n, ...)`

Histograma + escala log-log → PNG

9

Centralidades

`calcular_centralidades(G_1a3n, ...)`

Degree · Closeness · Eigenvector · PageRank · Betweenness (exata)

10

Louvain + validação

`detectar_comunidades_louvain(...)`

14 comunidades · heatmap comunidade × cadeia · ARI calculado

11

Visualização 3D

`plot_3d_comunidades(...)`

HTML interativo (Plotly) + PNG estático

12


Exportação

`exportar_resumo_txt(...)`


Resumo TXT + CSVs + PNGs em resultados/1A3N/

Resultados Esperados — 1A3N


Capturas geradas automaticamente pelo notebook — seções 8, 9 e 10




Histograma de graus (média = 9.89)



Escala log-log



Heatmap comunidade x cadeia




Histogramas de centralidades (Degree, Closeness, Eigenvector, PageRank, Betweenness)


Teste Rápido — Proteína de Teste (1A3N)

Hemoglobina humana · dirty-and-quick · resultados esperados antes de rodar o alvo

Distribuição de graus — 1A3N



Comunidade × cadeia



Esperado

574

Nós (Ca)

3 490

Arestas $\leq 8 \text{ \AA}$

14

Comunidades


$\approx 0,59$

Modularidade

$\approx 1,0$

ARI × cadeia

Distribuições das centralidades — 1A3N (Degree · Closeness · Eigenvector · PageRank · Betweenness)



Figuras salvas em resultados/1A3N/ · ARI e modularidade confirmam pipeline OK

Proteína-Alvo — 6B1T

Adenovírus Humano 5 · 25 cadeias · ~38 000 resíduos · 2 bundles PDB

13

Upload dos bundles

```
from google.colab import files; files.upload()
```

Upload obrigatório de bundle1.pdb e bundle2.pdb

14

Parsear resíduos

```
carregar_residuos_ca(pdb_files_6b1t, '6B1T')
```

Lê cadeias A–Y (Hexon, Penton e proteínas auxiliares)

15

Construir rede

```
construir_rede_por_distancia(df_6b1t, 8.0)
```

~38 000 nós · ~450 000 arestas · pode levar vários minutos

16

Distribuição de graus

```
plot_distribuicao_graus(G_6b1t, ...)
```

Histograma + log-log · salvos em resultados/6B1T/

17

Centralidades

```
calcular_centralidades(G_6b1t, k=300)
```

Betweenness aproximada (k=300) — reduz custo computacional

18-19

Louvain + Cadeia

```
detectar_comunidades_louvain(...)  
pd.crosstab(community, chain_id)
```

Heatmap comunidade × cadeia · modularidade e resumo CSV

20-22

Validação biológica

```
crosstab(community, familia_rcsb)  
crosstab(community, grupo_minimo)
```

Heatmap × família RCSB · validação mínima Hexon vs Penton

23-26


Métricas + 3D + ZIP

```
adjusted_rand_score / purity / NMI  
plot_3d_comunidades() + make_archive()
```


Métricas quantitativas · Plotly 3D · compactação e download

Resultados Esperados — 6B1T (I)

Distribuição de graus — Histograma e escala log-log



Distribuição de graus — 6B1T (média = 10.65)



Escala log-log

~38 000

Nós

~450 000

Arestas

10.65


Grau médio

30 (Louvain)

Comunidades

Resultados Esperados — 6B1T (II)


Distribuições das centralidades — Degree, Closeness, Eigenvector, PageRank, Betweenness



Seção 17 do notebook — Betweenness aproximada ($k=300$) por conta do tamanho da rede

Resultados Esperados — 6B1T (III)


Heatmap comunidade × cadeia — 30 comunidades Louvain × 25 cadeias (A–Y)




Resultados Esperados — 6B1T (IV)

Heatmaps de validação biológica — família estrutural RCSB e Hexon/Penton

Comunidade × Família estrutural RCSB




Comunidade × Hexon / Penton



⚠ **Critério mínimo:** Hexon (A–L) e Penton (M) devem pertencer a comunidades dominantes distintas. Verificar em rcsb.org/3d-view/6B1T

Resultados Esperados — 6B1T (V)

Heatmap comunidade × família estrutural (versão detalhada) e famílias mapeadas



Famílias Estruturais

A–L Hexon protein

M Penton protein

N, O Pre-hexon-linking IIIa

P, Q Pre-hexon-linking VIII

R, S, T Hexon-interlacing protein

U, V, X, Y Pre-protein VI

W Pre-histone-like nucleoprotein

Saídas:

6B1T_metrics_validacao_biologica.csv

Repositório e Declarações

Estrutura do repositório GitHub

Projeto_Redes_Complexas/

- |— arquivos/ # contém os arquivos 6b1t-pdb-bundle1.pdb e 6b1t-pdb-bundle2.pdb da proteína alvo
- |— resultados/ # CSVs, PNGs, HTML gerados automaticamente
- |— Projeto_Redes_Complexas_Proteina_Teste_1A3N_e_Proteina_Alvo_6B1T.ipynb # pipeline completo 1A3N + 6B1T
- |— README.md # instalação · execução · resultados esperados
- |— Relatorio_Redes_Complexas_Deteccao_de_Dominios_Funcionais.pdf # relatório final do projeto
- |— Slides_Projeto_Redes_Complexas.pdf # apresentação resumida e passo a passo p/ execução do projeto

Principais saídas do projeto

- ▶ X_residuos_ca.csv · X_arestas.csv
- ▶ X_metricas_rede.csv · X_distribuicao_graus.csv
- ▶ X_histograma_graus.png · X_graus_loglog.png
- ▶ X_centralidades.csv · X_top20_<metrica>.csv
- ▶ X_histogramas_centralidades.png
- ▶ X_comunidades_louvain.csv · X_resumo_comunidades.csv
- ▶ X_heatmap_comunidade_x_cadeia.png
- ▶ 6B1T_heatmap_comunidade_familia_rcsb.png
- ▶ 6B1T_metricas_validacao_biologica.csv
- ▶ X_3d_comunidades.html · resultados_*.zip

Uso de IA

Claude Sonnet 4.6 (Anthropic) — Estrutura dos slides.

Código revisado e validado pelo aluno.

Colaborações

Discussões gerais sobre modelagem de redes com colegas da disciplina. Código e relatório de autoria própria.

Linguagem

Python 3.x · Google Colab · NetworkX, python-louvain, BioPython, Plotly, scikit-learn, scipy, matplotlib.